

World Model + VLM Scorer для MiniGrid

Цель проекта - показать небольшую model-based RL систему, где агент в MiniGrid планирует действия через обученную модель мира и использует VLM-based scorer для оценки будущих состояний относительно текстовой цели: agent at the green goal.

Среда и данные

В качестве среды используется MiniGrid-Empty-5x5-v0. Агент стартует в небольшой комнате и должен дойти до зелёной клетки-цели. Данные для модели мира собраны из MiniGrid путём перебора допустимых позиций агента, направлений взгляда и действий навигации: left, right, forward. Всего получено 3240 переходов, включая 60 переходов с положительной наградой за достижение цели.

Модель мира

Модель мира реализована как компактная RSSM-style модель в духе PlaNet/Dreamer. Она хранит рекуррентное скрытое состояние h_t и stochastic latent state z_t . По текущему состоянию и действию модель предсказывает следующий нормализованный state агента, reward и вероятность done. Во время планирования candidate action sequences прокручиваются внутри этой learned world model на горизонте $H=14$.

VLM scorer и планирование

Для VLM scorer используется CLIP ViT-B/32 из open_clip. Возможные будущие состояния рендерятся как RGB-кадры MiniGrid и сравниваются с текстовой целью. Важно, что VLM-score применяется к imagined future states из rollout-a, а не только к текущему наблюдению. Планировщик использует MPC/random shooting: на каждом шаге сравнивает 768 кандидатных последовательностей действий, выполняет первое действие из лучшей последовательности и затем планирует заново.



Baseline-сравнение

Сравниваются три варианта: random policy, planning в world model без VLM-score и planning в world model с VLM-score. В последнем варианте также используется небольшой goal-distance stabilizer, потому что CLIP обучался в основном на естественных изображениях, а MiniGrid-кадры являются символическими.

Количественные результаты

Метод	Эпизоды	Success rate	Mean return	Mean steps
Random	30	0.40	0.307	34.3
World model planning	30	0.73	0.610	24.3
World model + VLM	30	0.80	0.682	21.1


Оценка проводилась на 30 эпизодах с seeds 0-29. Максимальная длина эпизода - 40 шагов, horizon планирования - 14, число random-shooting candidates - 768.




Визуализация эпизодов

Ниже показаны раскадровки трёх GIF-примеров из `reports/assets/`. В самом репозитории эти эпизоды сохранены как анимированные GIF.


Random policy



World model planning



World model + VLM



Основные проблемы

1. CLIP-score на MiniGrid шумный, потому что изображения символические и сильно отличаются от естественных изображений из pretraining.
2. Компактная RSSM хорошо подходит для Empty-5x5, но это не полный pixel-level Dreamer. Для более сложных сред нужен stronger decoder и более богатое latent state.
3. Random shooting прост и нагляден, но sample-inefficient: рост числа candidates улучшает планирование, но увеличивает время работы на CPU.
4. В простой среде reward-only planning уже достаточно силён, поэтому VLM-term требует аккуратного веса.

Что можно улучшить дальше

Дальше логично перейти к DoorKey-8x8, обучить pixel decoder и применять VLM напрямую к decoded imagined frames. Также можно заменить random shooting на CEM, добавить uncertainty-aware planning и проверить цели вроде 'agent next to the key', где языковая цель может быть полезнее простой reward-эвристики.

Файлы

PDF-отчёт, графики и GIF-примеры лежат в `reports/`. Данные, checkpoints и evaluation CSV воспроизводятся скриптами и сохраняются локально в `artifacts/`.